

추천시스템 사례조사

: 쿠키런, 유튜브 알고리즘

당신의
가장 가까이 있는
추천 알고리즘은
무엇인가요?




〈쿠키런:오븐브레이크〉 페탈출 조합 추천 시스템,
추천 시스템이 도입된 이후 아이템 구매 유저는 3배 가까
이 늘었고, 신규 유저의 매출은 79% 증가했다.

발란, AI 개인화 추천 광고 활용...입점사 매출 최대
2000%

#추천시스템 #성공사례

PROBLEM

당신의 데이터는 무엇인가요?




쿠키런에서는,



데탈출 이용자들 등급 분석
(최고 등급 미달성자 비율 94.7%)



신규 유저들의 최고 등급 도달 전후 비교
(최고 등급 도달 이후 구매를 더 많이 하는 경향 파악)



조합 : 쿠키 184개, 펫 190개, 보물 103개 중 3개 선택



클릭



유저의 기존 조합과 그리디 알고리즘을 이용한 추천을 섞는 모델 개발

유저의 기존 조합이
최소한으로 존재해야 함.



'그리디 알고리즘'

매 순간 선택에서 당장 최적의 답을
선택하고, 적합한 결과를 도출. 하지
만 반드시 그러하지 않다.

아이템 구매 유저



3배

신규 유저의 매출



79%

데탈출 에피소드에서 3명 중 1명
추천시스템 이용


머신러닝, 딥러닝 경우의 효과는?

Deep Neural Networks for YouTube Recommendations


Paul Covington, Jay Adams, Emre Sargin
Google
Mountain View, CA
(pcovington, jka, msargin)@google.com

- Youtube, 영상 시청의 **70%** 가 추천 영상.
- 발란, 투입 광고비 대비 최대 **2000%**의 괄목할 만한 매출 증가 효과(ROAS)를 보임.

1) Top-N : 상위의 N 개의 아이템




사용자에게 찾을 수 있는 최고의 콘텐츠를 이와 같은
최상위 N 목록 형식으로 배치



일반적으로 각 사용자의 개인적인 관심사를 나타내
는 일부 데이터가 필요함
(과거에 구입 한 물건과 같은 암시적 등급)

2) 콘텐츠 기반 필터링

: 내용(Content)에 알맞는 아이템을 추천해주는 것




유저가 좋아한 아이템들을 뽑아낸 목록을 Item Profile

Item Profile로부터 공통된 특징을 뽑아낸 결과가 User Profile

3) 하이브리드 추천 시스템 (Hybrid Recommender Systems)

What is Hybrid Recommender System?



협업 필터링과 콘텐츠 기반 필터링 기술을 결합하여 각각의 장점을 활용하여 보다 정확한 추천을 제공함으로써 한계를 극복함.

(예를 들어 콘텐츠기반 필터링 같은 경우는 신규 유저에게 추천을 잘해주지 못하는 단점이있었지만, 추천 결과를 협업기반 필터링 추천 알고리즘과 결합한다면 추천 효과를 더 높일 수 있음)

4) 협업필터링 : 사용자, 아이템기반



1. "평점 유사도"를 기반으로 나와 유사한 사용자 (Users)들을 찾음
2. 유사한 사용자가 좋아한 Item을 추천

1. 특정 Item을 좋아한 사용자들을 찾음
2. 그 사용자들이 공통적으로 좋아했던 다른 Item을 찾음
(사용자들의 평가패턴을 바탕으로 아이템간의 유사도를 계산해서
사용자의 특정 아이템에 대한 예측 평점을 계산함.)


4) 협업필터링 : 사용자, **아이템**기반



2003년 Amazon에서 발표한 Item-to-Item
Collaborative Filtering



2018년에 출시된 Personalize
개인화 추천 시스템
(아마존의 30%이상 페이지 뷰는
recommendations에서 이루어짐.)



Two Decades of Recommender Systems at Amazon.com





Figure 2: Recommendation system architecture demonstrating the “funnel” where candidate videos are retrieved and ranked before presenting only a few to the user.


The Netflix Recommender System: Algorithms, Business Value, and Innovation




과거 YouTube 시스템 구성

2016년 발표된 논문은 기본적인 딥러닝 모델을 도입하여 그 기반을 만드는데 초점이 맞춰져 있다.

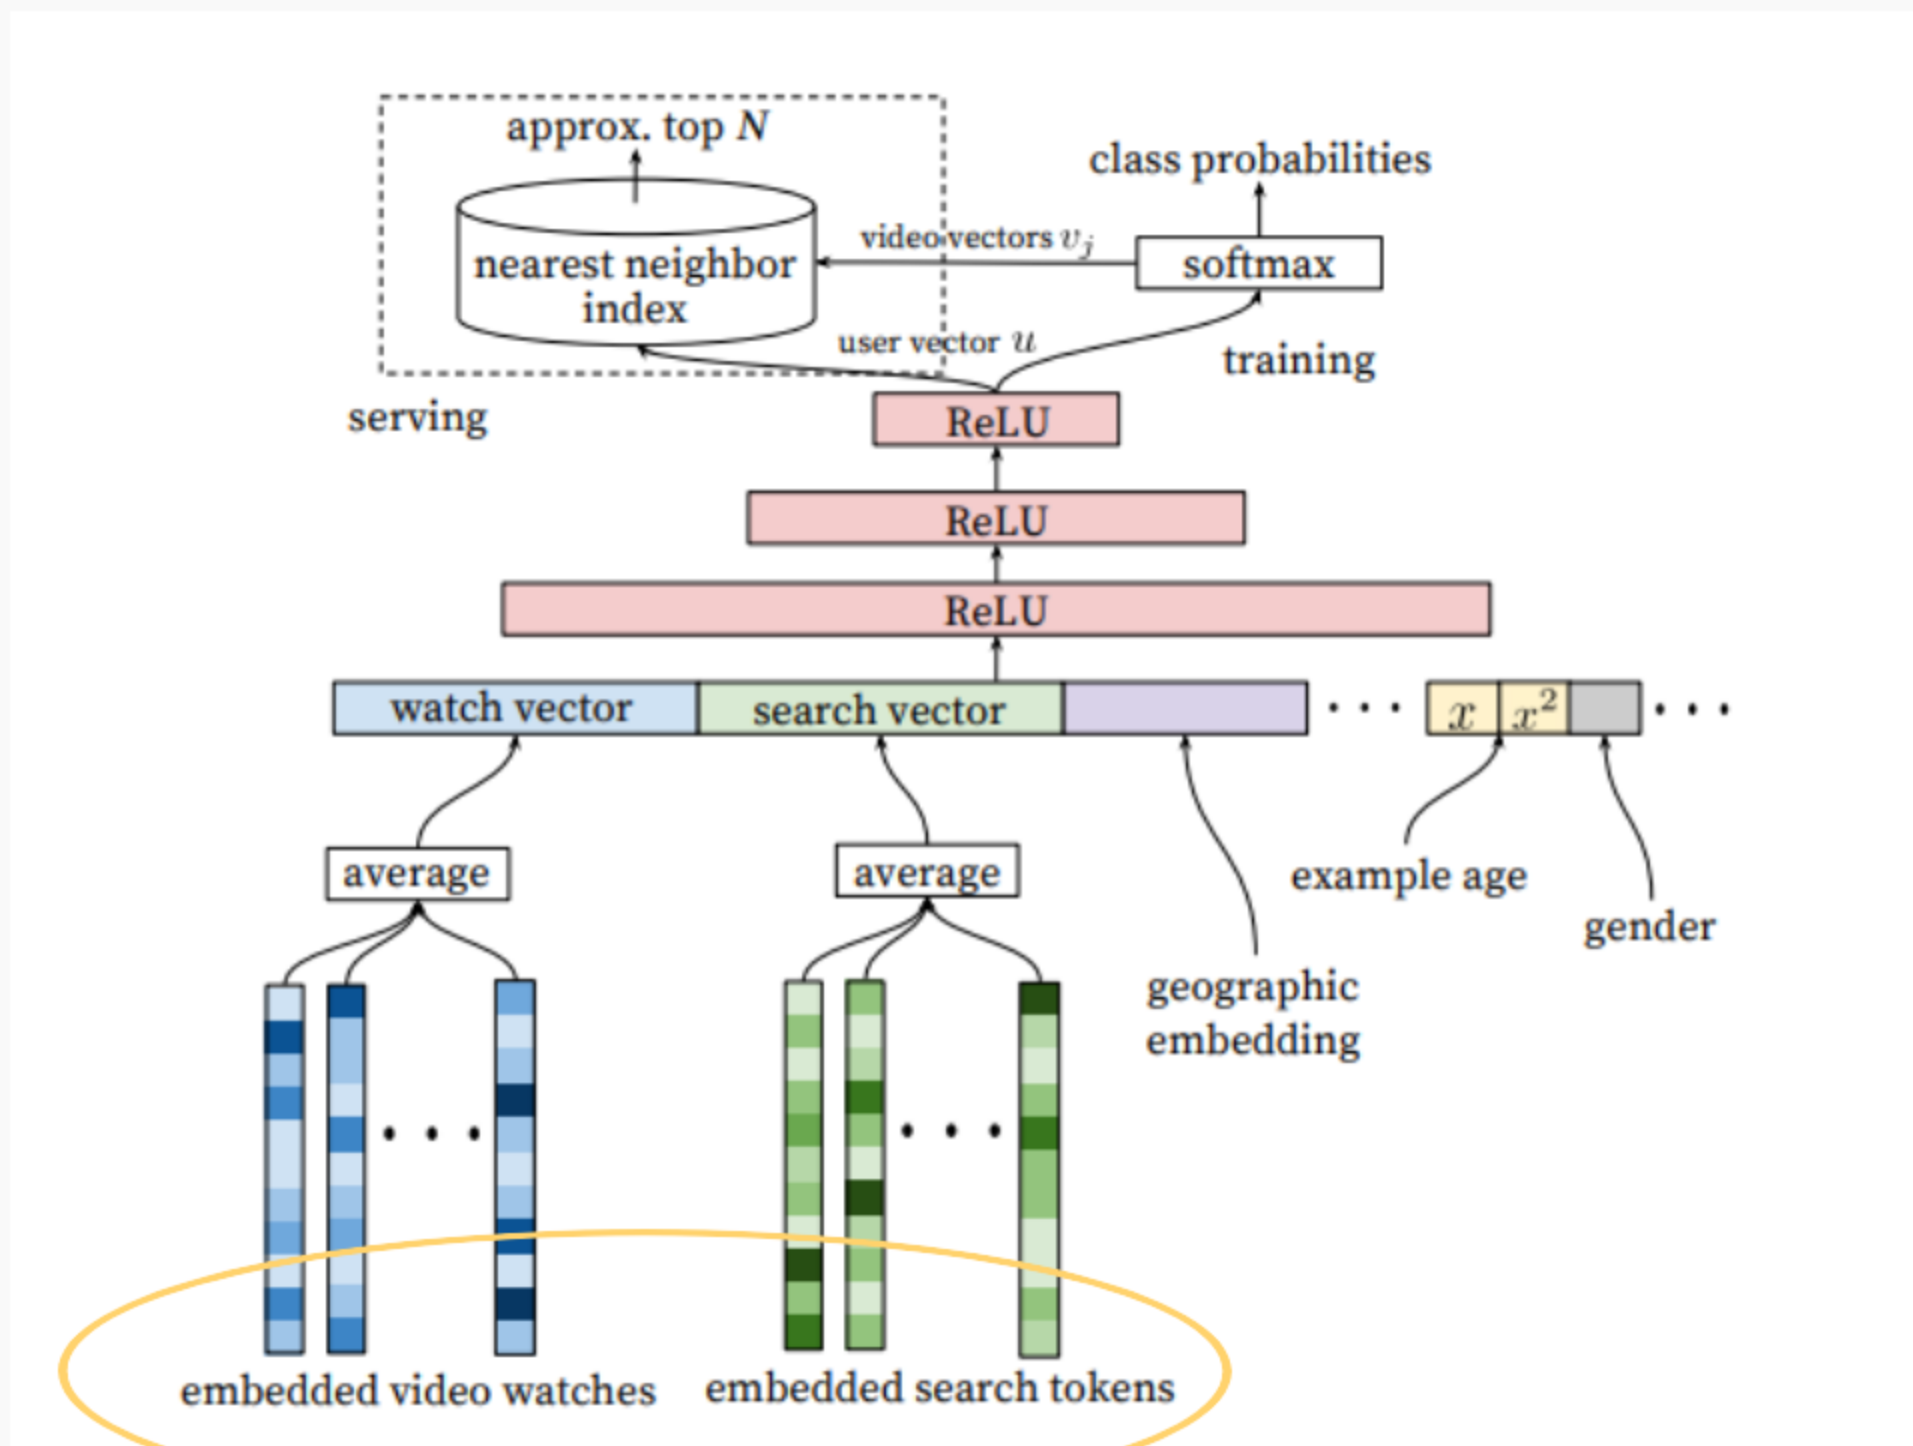
2개의 딥러닝 모델로 구성되어 있는데, Candidate generation 모델은 유튜브 영상 중 유저가 좋아할 만한 비디오 후보를 수백개 수준으로 특정한다.



ranking 모델은 그 비디오들 중에서 실제로 유저가 시청하게 될 만한 추천 목록을 만든다.



과거 YouTube 시스템 구성 (1) 후보 생성(candidate generation) 모델




*모델에서 가장 주요한 부분은 시청기록과 검색기록을 이용하는 부분

1. 좌측 하단에 임베딩들을 보면 비디오 혹은 검색 토큰마다 벡터형태를 취하고 있는데, 정답 없이 데이터를 활용하여 학습하는 방법 중 하나로 학습됨.
2. 기록은 개수가 상황에 따라 다르기 때문에 입력 벡터의 크기를 고정하기 위해 두 기록을 각각 평균을 내어 사용함.
3. 이 외에도 유저의 기본적인 정보들과 함께 유저가 최신 콘텐츠를 선호하는 경향을 고려하여 비디오 업로드가 얼마나 오래됐는지(age)도 입력으로 사용함.

학습방법:

위 입력을 기반으로 특정 비디오에 대한 시청 여부를 이용해 시청 확률을 추정하도록 학습함.

과거 YouTube 시스템 구성 (2) ranking 모델



*수백만 개에서 수백 개로 후보가 줄어들었기 때문에 더 정교한 방식을 사용할 수 있음.

1. 딥러닝을 이용한 임베딩만으로는 부족하여, 다양한 feature engineering(feature를 여러 방식으로 가공하는 것)을 통해 입력을 추가로 확장함.

(딥러닝 모델이 이해하기 쉬운 형태로 feature를 제공해주는 것은 모델의 성능을 향상시키는 데에 여전히 많은 도움을 줌.)


학습방법 :

시청 시간에 따른 가중치를 주고 학습함.

→ 이를 통해 학습된 모델은 서빙 시에 적절하게 점수화 하고, 이를 정렬하여 유저에게 제공

과거 YouTube 시스템 구성

2019년 Recommending What Video to Watch Next: A Multitask Ranking System¹에서 제안한 내용



좀 더 고도화된 추천을 위해 ranking 모델을 개선하는 것에 초점이 맞춰져 있음.

모델의 성능을 높이기 위해 다수의 레이어로 구성된 깊은 모델 구조를 만드는 것이 대표적인 방법 이지만, 모델 깊게 만들면 속도가 느려지기 때문에 유튜브는 실시간으로 유저에게 추천 목록을 제공하기 위해 얇은 모델로 구성해야 함.

→ 따라서 효과적으로 학습하고, 효율적으로 서빙해야 함

(논문에서 제안하는 방법 3가지)

1. 유튜브 ranking에 맞춤형된 multi-task 학습 목표 설정
2. multi-task 문제에서 필요한 정보를 더 효율적으로 추출하는 모델 구조
3. feedback loop에서 발생하는 selection bias 처리

감사합니다.

